

机器学习

杨铁龙

2018年9月17日

1 问题的定义

1.1 项目概述

自然语言处理(NLP)属于人工智能的分支，作用于将自然语言转化为计算机语言进行处理，以及将计算机语言转化为自然语言进行表达^[1]。自然语言在现代人工智能产品中应用广泛，尤其在智能语音方面，自然语言成为人机交互的纽带。当前自然语言处理仍面临诸多挑战，文章的表达分析是其中之一。单词边界、词义以及行为推理都是影响文章推理问题的因素，统计语言中统计概率模型，但是难以确认词与词的关联性，影响到文本分析的准确性^[2]。

本文将借助20类新闻包^[3]和text8^[4]作为实验样本,尝试词袋模型BOW^[5]和词向量模型Word2Vec^[6]分析并表示样本数据中的每篇文章，然后作为输入向量，选取机器学习模型进行训练并与之前的词袋模型进行对比分析，验证词向量模型在表达分析问题上的准确性提升。

1.2 问题描述

本文将使用20类新闻包和text8作为样本进行训练分析，这是一个多分类的有监督学习问题。

本文将使用BOW和Word2Vec模型提取并表示样本数据中的每篇文章，需要考虑到数据的解析问题，准确把握数据的分类特征，然后利用机器学习模型决策树模型、支持矢量机(SVM)模型、朴素贝叶斯模型和神经网络模型进行训练，并选择准确性比较高进行性能评估。

通过对比验证BOW和Word2Vec模型在表示样本数据上准确性，验证词向量模型在表达分析问题上是否使准确性提升。

1.3 评价指标

本文中选取合适的文本表示模型和机器学习分类模型进行训练，完成后分别计算各自的准确率进行性能评估，验证Word2Vec是否确实改善了本文分析推理。

$$accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

准确性可以有效的反映出BOW和Word2Vec模型在表示样本数据的性能，可以满足本文想验证词向量模型在表达分析问题上是否使准确性提升的需求。

2 问题的定义

2.1 数据的探索

分类的文本数据为经典的20类新闻包，包含约20000条新闻，较均衡的分成了20类，是较常用的文本分类数据之一。项目中可以通过 `sklearn.datasets.fetch_20newsgroups` 方法进行引用，获取数据时通过指定 subset 为 train 或者 test 来指明

数据用来训练还是测试，有效且方便训练模型并进行验证。20类新闻包中包含18846个样本数据，其中有11314个训练样本和7532个测试样本，按照交叉验证思想将训练集再拆分出20%验证集进行训练，所以最后为9051个训练集样本，2263个验证集样本和7532个测试集样本。

每个样本特征中包含作者、主题、组织和行数等头部信息，以及引用和正文信息，最后包含作者信息。标签则为对应类别的序号,如下图所示：

```
From: djf@cck.coventry.ac.uk (Marvin Batty)
Subject: Re: Moonbase race
Nntp-Posting-Host: cc_sysk
Organization: Starfleet, Coventry, UK
Lines: 22

In article <lr46o9INN14j@mojo.eng.umd.edu> sysmgr@king.eng.umd.edu writes:
>In article <C5tEIK.7z9@zoo.toronto.edu>, henry@zoo.toronto.edu (Henry Spencer) writes:
>
>>Apollo was done the hard way, in a big hurry, from a very limited
>>technology base... and on government contracts. Just doing it privately,
>>rather than as a government project, cuts costs by a factor of several.
>
>So how much would it cost as a private venture, assuming you could talk the
>U.S. government into leasing you a couple of pads in Florida?
>
Why use a ground launch pad. It is entirely possible to launch from altitude.
This was what the Shuttle was originally intended to do! It might be seriously
cheaper.


Also, what about bio-engineered CO2 absorbing plants instead of many LOX bottles?
Stick 'em in a lunar cave and put an airlock on the door.

--
*****
Marvin Batty - djf@uk.ac.cov.cck
"And they shall not find those things, with a sort of rafia like base,
that their fathers put there just the night before. At about 8 O'clock!"
```

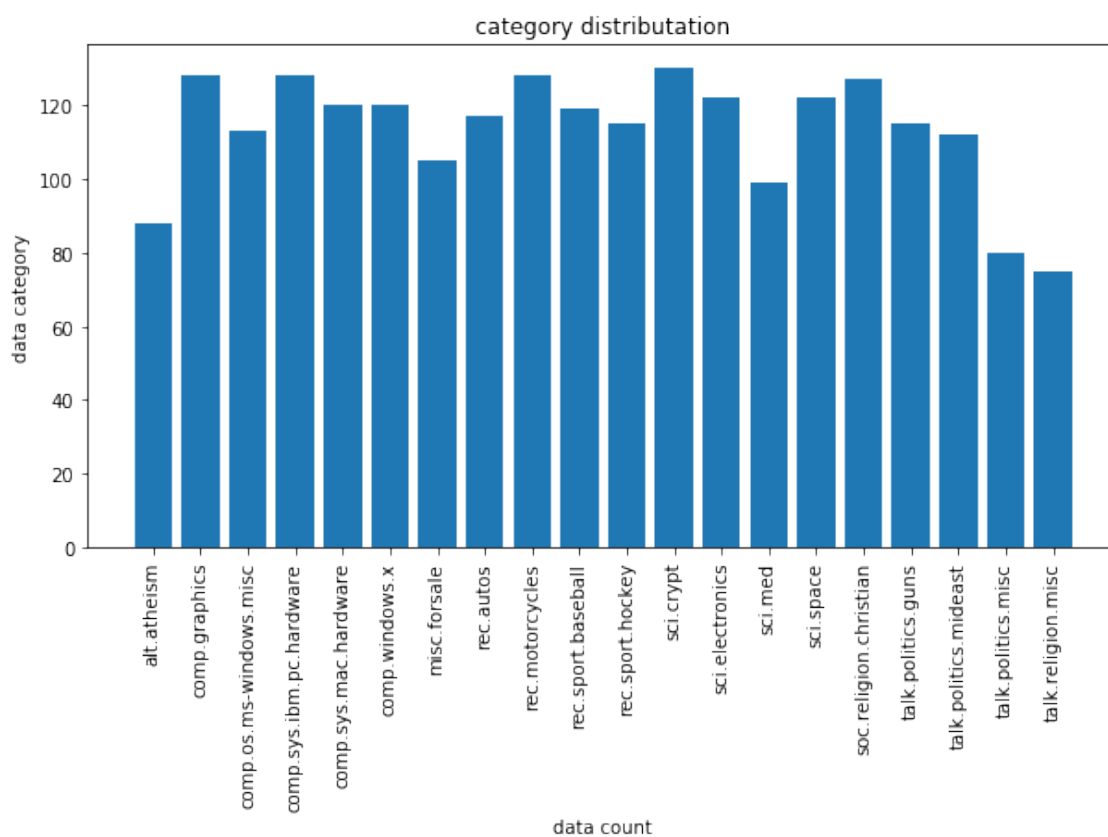
样本类别包含alt.atheism、comp.graphics和comp.os.ms-windows.misc等20个类别。

2.2 探索性可视化


训练集中样本分布如下：



验证集中样本分布如下：

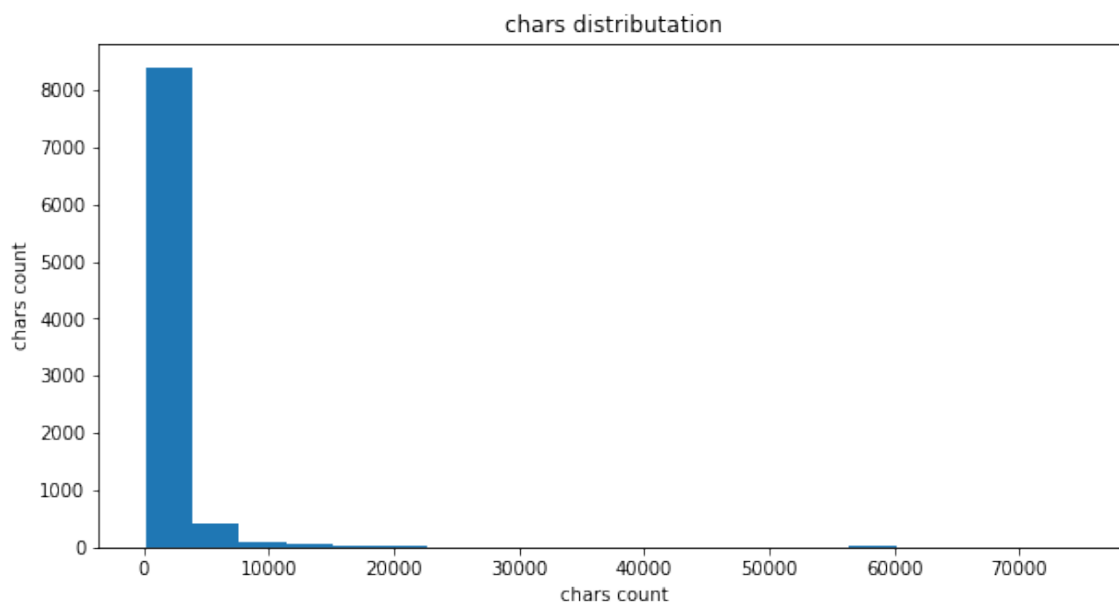


测试集中样本分布如下：




由上图可见，每个数据集中类别分布较为均匀，alt.atheism和talk.religion.misc稍微较少。并且训练、验证和测试集中类别分布也较为相似，对训练后测试影响较小。

新闻数据长度分布如下，大部分少于15000个字符：



新闻数据词频分布如下，大部分少于2000个单词：



2.3 算法和技术

本文中文本表示模型中以词袋模型BOW为基准模型，并加权词频TF-IDF向量，在文本预处理中，选择出现个数大于2，频率小于0.95的词建立词袋模型。而词向量模型选择Word2Vec来表示每篇文章，Word2Vec中将借助text8训练集来建立文本表示模型。

机器学习模型中，由于词袋模型无法难以表达文本中词之间的关联性，适用于传统机器学习模型，但不适合text-cnn模型。而Word2Vec可以用维数较少的向量表达词以及词之间的关联性，适用于text-cnn模型，但由于维度差异的存在，不适用于机器学习模型。因此将通过决策树模型、支持矢量机(SVM)模型和朴素贝叶斯模型对BOW并加权词频TF-IDF^[7]向量后输出的数据进行训练。而通过text-cnn^[8]模型训练Word2Vec输出的数据。

2.4 基准模型

本文将以Bag-of-words模型(BOW)作为基准文本表示模型。BOW模型对于一个文本分析时，会忽略其中的语法和词序，将其分割并建立一个词集。文章^[8]中基于BOW对20newsgroups分析时结合SVM准确率约为87.15%,本文将以此作为对比。

3 方法

3.1 数据预处理

文章的预处理中包括:

- 1) 去除标点符号符号，然后使用空格符分割原有文章，将文章装换成单词数组。
- 2) 建立TF-IDF时,只使用频率低于0.97，数量高于2个的单词进行训练，过滤掉其他的。
- 3) stop_words使用'english', 减少停用词带来的消极影响。

将训练集通过CountVectorizer和TfidfVectorizer建立BOW和TF-IDF词袋模型。TF-IDF加权后所建立的训练集如下图所示：

```
(0, 6531)      0.22547672131238686
(0, 18108)     0.05419741635179298
(0, 46052)     0.030606072982409156
(0, 40335)     0.11015011337594552
(0, 25268)     0.07987346301365322
(0, 43700)     0.04700116862960857
(0, 8157)      0.04238054196688091
(0, 15109)     0.10447882624095957
(0, 1674)      0.06198853857973
(0, 1453)      0.07243094287068748
(0, 2051)      0.07243094287068748
(0, 33136)     0.008363216499216836
(0, 6929)      0.05679156273679379
(0, 13421)     0.05340624841432061
(0, 27064)     0.03871798282058418
(0, 22424)     0.08297421642223916
(0, 45630)     0.015594069482677818
(0, 4297)      0.04213992125703991
(0, 2748)      0.07011882723114268
(0, 2489)      0.07011882723114268
(0, 31832)     0.05108821106604819
(0, 39972)     0.0361475466264802
(0, 45164)     0.09446162859245455
(0, 17617)     0.045886923316482225
(0, 43427)     0.05202507904455907
:              :
```

将训练集通过gensim.models建立词向量模型word2vec，并利用text8训练集进行训练。

3.2 执行过程

执行过程中主要需要：

1) 通过sklearn中DecisionTreeClassifier，SVC和MultinomialNB分别对TF-IDF建立表示的数据集进行训练，训练时需要将训练集，验证集和测试集分开处理，并记录结果，如下图所示。同时选择这个模型中最优的参数组合使得训练结果最优，因此借助GridSearchCV工具来进行训练。

```
{'model_name': 'DecisionTreeClassifier', 'train_time': 8.37720775604248, 'test_time': 0.05581521987915039, 'train_score': 0.9998895149707214, 'test_score': 0.6451612903225806}
{'model_name': 'SVC', 'train_time': 75.76889228820801, 'test_time': 51.30510997772217, 'train_score': 0.9938128383604021, 'test_score': 0.9151568714096332}
{'model_name': 'MultinomialNB', 'train_time': 0.04885721206665039, 'test_time': 0.025672197341918945, 'train_score': 0.9594519942547785, 'test_score': 0.8859920459566947}
```

2) 通过textcnn对word2vec建立的数据集进行训练，首先借助于keras工具绘制textcnn模型图，如下图所示。

embedding matrix shape: (20001, 100)

Layer (type)	Output Shape	Param #	Connected to
input_2 (InputLayer)	(None, 1000)	0	
embedding_2 (Embedding)	(None, 1000, 100)	2000100	input_2[0][0]
reshape_2 (Reshape)	(None, 1000, 100, 1)	0	embedding_2[0][0]
conv2d_4 (Conv2D)	(None, 996, 1, 100)	50100	reshape_2[0][0]
conv2d_5 (Conv2D)	(None, 997, 1, 100)	40100	reshape_2[0][0]
conv2d_6 (Conv2D)	(None, 998, 1, 100)	30100	reshape_2[0][0]
max_pooling2d_4 (MaxPooling2D)	(None, 1, 1, 100)	0	conv2d_4[0][0]
max_pooling2d_5 (MaxPooling2D)	(None, 1, 1, 100)	0	conv2d_5[0][0]
max_pooling2d_6 (MaxPooling2D)	(None, 1, 1, 100)	0	conv2d_6[0][0]
concatenate_2 (Concatenate)	(None, 1, 1, 300)	0	max_pooling2d_4[0][0] max_pooling2d_5[0][0] max_pooling2d_6[0][0]
flatten_2 (Flatten)	(None, 300)	0	concatenate_2[0][0]
dropout_2 (Dropout)	(None, 300)	0	flatten_2[0][0]
dense_2 (Dense)	(None, 20)	6020	dropout_2[0][0]
Total params: 2,126,420			
Trainable params: 126,320			
Non-trainable params: 2,000,100			

训练过程中发现由于训练集较大，在借助GridSearchCV对SVC训练时所需时间较长，因此借助于cpu_count来进行多核运算，提高效率。

3.3 完善

在进行对TF-IDF建立的数据集训练时，本文先借助机器学习默认参数对数据集进行训练，然后借助与GridSearchCV进行参数优化。如下图所示，由于训练的不稳定型，决策树模型在优化后确出现了准确率下降，不过SVC和NaiveBayes整体上仍处于被优化状态。并且SVC显示出准确率更好。

模型	优化前训练acc	优化前验证acc	优化后训练acc	优化后验证acc
DecisionTreeClassifier	0.9998895149707214	0.6451612903225806	0.8809053700295849	0.6228566377938837
SVC	0.9938128383604021	0.9151568714096332	0.9992486986939868	0.9065759236344352
MultinomialNB	0.9594519942547785	0.8859920459566947	0.9983207266996299	0.8891638677744388

对word2vec建立的数据集进行训练时，由于batchsize调整较为困难，本文通过一定范围内加大epochs，可以优化textcnn最终训练的结果。

4 结果

4.1 模型的评价与验证

针对TF-IDF的传统机器学习模型中，通过原始的默认参数训练，以及借助于GridSearchCV挖掘最优参数，如下图所示，可以发现SVC的表现最好，符合SVC的特点，虽然训练时间较长，但是泛化能力强，能提供较高的准确率。SVC在初始模型以及优化后的模型中都表现最优，并且也在最后的测试中得到了体现，因此比较可靠。

```
DecisionTree best score 0.5582846521508231
svc best score 0.8328465215082316
NaiveBayes best score 0.8096123207647371
```

如下图所示，针对word2vec的text_cnn模型，参考了Yoon Kim的model，并未有参数的较大改变，但是通过其训练过程可以发现是文件可靠的。

```
7532/7532 [=====] - 26s 3ms/step
[0.9194534627035205, 0.7299522037083205]
```


4.2 合理性分析

SVC配合TF-IDF训练的过程中所表现出的训练时间长符合其特点，并且在传统模型中最优的准确率也符合其良好的泛化能力。并且SVC可以借助于GridSearchCV继续挖掘更有参数，优化模型。


text_cnn配合word2vec所表现出的准确率一定范围内会随着epochs增加而增加，而0.919的准确率也体现出其较好的文本识别能力，符合cnn模型在文本识别上较高的准确率。

5 项目结论

5.1 结果可视化



如上图所示，为优化后传统机器学习模型对TF-IDF所表示的数据训练的过程和表现。SVC训练时间明显突出，但是准确率也是三个模型中最好的，因此在传统模型中应该选择SVC。



如上图所示，为textcnn对word2vec所表示的数据训练的过程和表现。可以看到模型随着epochs在训练集上准确率会越来越高，

但是测试集上在15以后就出现略微增长了，说明textcnn可能存在过拟合风险。但是测试的准确率较高并且仍处于缓慢增长。

	SVC+TF-IDF	text_cnn+word2vec
最终测试准确率	0.8328465215082316	0.9194534627035205

说明了text_cnn+word2vec组合可以提供更高的准确率，并且在训练集测试集上都表现较好，说明较为稳定可靠。

5.2 对项目的思考

本文针对词边界、词义以及行为推里都是影响文章推理问题的因素，统计语言中统计概率模型，和词袋模型难以确认词与词的关联性问题，提出验证word2vec能否有效解决问题。

本文首先通过建立BOW模型，并进行TF-IDF向量加权，建立训练集，然后通过传统机器学习模型决策树模型、支持矢量机(SVM)模型、朴素贝叶斯模型进行训练，并借助于GridSearchCV优化模型参数，最终获得较好的模型并发现SVC效果最佳。虽然训练过程中SVC所需时间较长，但还是通过cpu_count并发运行解决。

本文通过建立word2vec模型，建立训练集，然后通过keras绘制text_cnn卷积图，通过训练并且调整epochs获得最终较优的模型，并发现其准确率较高。

论述了SVC和text_cnn分别对于TF-IDF和word2vec的合理性，并通过最终的测试对比得出word2vec模型的确改善了文本识别能力。并通过训练和测试对比，发现其是可靠的。

5.3 需要作出的改进

本文中对传统机器学习模型优化时，借助于GridSearchCV，但所列的参数列表可能有限，并未覆盖到最优参数组合。可以增加参数组合继续优化。

本文中对别词袋模型和词向量模型时，借助了不同的机器学习模型进行验证，但其实未能规避机器学习模型带来的影响，实验结果并不一定准确。可以寻找机器学习模型能够同时兼容两个文本表示模型的方法。

6 参考文献

[1] <https://zh.wikipedia.org/wiki/自然语言处理>

[2] https://github.com/nd009/capstone/tree/master/document_classification

[3] <http://www.qwone.com/~jason/20Newsgroups/>

[4] <http://mattmahoney.net/dc/text8.zip> [5] <http://www.cnblogs.com/platero/archive/2012/12/03/2800251.html>

[6] <https://radimrehurek.com/gensim/models/word2vec.html>

[7] <https://baike.baidu.com/item/tf-idf/8816134?fr=aladdin>

[8] <https://arxiv.org/abs/1408.5882>

[9] <https://dl.acm.org/citation.cfm?id=2390688>